

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ "НИЖЕГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ
ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ИМ. Р.Е.АЛЕКСЕЕВА"

Яковлев Олег Алексеевич

**МОДЕЛЬ И АЛГОРИТМЫ ПРОГНОЗИРОВАНИЯ
СОСТОЯНИЯ ПОДШИПНИКА КАЧЕНИЯ**

Специальность 09.04.01 —
«Информатика и вычислительная техника»

Диссертация на соискание учёной степени
магистра

Научный руководитель:
к.т.н., доцент
Гай Василий Евгеньевич

Нижний Новгород — 2017

Оглавление

	Стр.
Введение	4
Глава 1. Обзор существующих подходов к прогнозированию состояния механизмов	7
1.1 Общие положения прогнозирования	7
1.2 Классификация подходов к прогнозированию	8
1.3 Подходы к прогнозированию на основе данных	10
1.4 Классификация подходов к прогнозированию на основе данных .	14
1.5 Оценка эффективности подходов к прогнозированию	18
1.6 Метод на основе пакетного вейвлет-разложения и скрытых Марковских моделей	20
1.7 Метод на основе быстрого преобразования Фурье и одноклассового метода опорных векторов	23
Глава 2. Информационная модель качественной и количественной оценки состояния подшипника	25
2.1 Теория активного восприятия	25
2.2 U-преобразование	25
2.3 Реализация системы вибродиагностики с использованием теории активного восприятия	28
2.4 Классификация	31
2.5 Описание алгоритма.	36
Глава 3. Вычислительный эксперимент	39
3.1 Эксперимент	39
3.2 Выводы	42
Заключение	43
Список сокращений и условных обозначений	44
Список литературы	45

Список литературы	47
Список рисунков	47
Список таблиц	49

Введение

Любой механизм с течением времени изнашивается и, соответственно, возрастает риск поломки. Однако неожиданный выход из строя оборудования может нести более серьезные последствия, чем временные простои в производстве или задержки в обслуживании клиентов. С ростом масштабов и технологичности производств, в некоторых случаях, поломки могут становиться причиной гибели людей или невосполнимого урона окружающей среде. Это создает необходимость в своевременном обслуживании изношенных деталей механизмов.

Принимая во внимание недавние достижения в современных технологиях, индустрия и исследователи переходят к улучшенным системам поддержки и обслуживания оборудования, которые нацелены на увеличение степени надежности и пригодности важных промышленных активов и уменьшение стоимости обслуживания. Возникли тенденции на переход от ремонта по факту отказа к системам, позволяющим спрогнозировать и предотвратить неполадки. В рамках прогностического подхода осуществляется постоянное наблюдение за состоянием компонентов промышленной системы, и оценка текущего состояния на основе собранных данных. Таким образом прогнозирование становится необходимым шагом к предупреждению отказов изнашивающегося оборудования в будущем и оценке остаточного ресурса работы. Имея на руках эффективную систему прогнозирования изменений в состоянии деталей становится возможным чтобы соответствующие меры (например, техобслуживание либо смена нагрузочного профиля) были приняты вовремя, что позволяет избежать больших затрат, связанных с поломками и отказами.

Промышленное оборудование работает в динамически меняющейся среде, поведение которой нелинейно в связи со многими факторами, такими как температура, давление, уровень шума и т.д. Так, собранные данные о состоянии системы подвержены неопределенности. Также, недостаток знания о сложном процессе износа, делает прогноз поведения механизмов серьезной проблемой. Несмотря на то, что в последнем десятилетии было предпринято несколько попыток внедрения, реальные системы прогнозирования состояния механизмов все ещё мало распространены. Сложная эксплуатационная среда промышленных систем осложняет разработку эффективных подходов к прогнозированию

которые были бы: достаточно гибкими чтобы допускать неопределенность, достаточно надежными, чтобы показывать хорошие результаты в разнообразных условиях и применимыми в промышленных рамках.

Таким образом необходимы улучшенные подходы к диагностике сбоев и аномалий в компонентах производственных систем с целью оценки остаточного ресурса работы. В качестве целевого компонента для диагностики был выбран подшипник качения, так как это один из наиболее распространенных компонентов в промышленности и присутствует практически во всех индустриальных процессах - всюду где используются вращающиеся элементы. Более того, поломка подшипника это одна из самых частых причин выхода из строя таких деталей.

Оценка остаточного времени работы подшипника строится на обработке вибрационного сигнала. Выделяются и анализируются признаки, наиболее точно отражающие процесс поломки.

Целью данной работы является исследование существующих методов вибродиагностики состояний подшипников качения, разработка собственного метода вибродиагностики, а также выполнение эксперимента в целях проверки работоспособности разработанного алгоритма.

Основные положения, выносимые на защиту:

1. информационная модель оценки состояния подшипника качения;
2. признаковое описание используемое в разработанной модели вибродиагностики;
3. экспериментальное исследование, подтверждающее состоятельность разработанной модели.

Научная новизна: работы заключается в разработанной системе признаков на основе спектральных коэффициентов.

Степень достоверности и обоснованность данной работы подтверждается корректным использованием современных подходов к цифровой обработке сигналов и проведению вычислительных экспериментов. Полученные результаты исследования подтверждаются экспериментальными данными. Достоверность данной работы также подтверждает представленный анализ современных методов вибродиагностики подшипников качения, а тестовые данные, использованные для проведения вычислительных экспериментов, являются широко

используемыми в научных работах по аналогичной тематике, что также подтверждает достоверность полученных результатов.

Объем и структура работы. Диссертация состоит из введения, трех глав, заключения и приложения. Полный объём диссертации составляет 49 страниц с 24 рисунками и 4 таблицами. Список литературы содержит 15 наименований.

Глава 1. Обзор существующих подходов к прогнозированию состояния механизмов

1.1 Общие положения прогнозирования

Под прогнозированием в инженерной сфере понимается процесс отслеживания состояния объекта и оценка временного интервала, по истечению которого, данный объект перестанет выполнять возложенную на него функцию. Объектом прогнозирования может быть любое устройство или деталь устройства. В литературе можно найти множество определений прогнозирования, приведем из них несколько:

1. Способность заранее распознавать предпосылки поломки компонента устройств и предсказывать переход от предпосылок к реальной поломке.
2. Проактивная диагностика, которая включает в себя оценку остаточного времени штатной работы детали или устройства.
3. Прогнозирование включает в себя предсказание уровня деградации компонента системы основываясь на наблюдаемом состоянии данной системы.

Обобщая определения можно заключить, что прогнозирование сводится к оценке остаточного ресурса штатной работы компонента. Единицы измерения этого ресурса зависят от объекта прогнозирования. Для автомобильного двигателя это будет количество километров, которое осталось проехать автомобилю до поломки, для подшипника это может быть количество оборотов. С помощью данных получаемых в результате прогнозирования можно производить своевременную замену изношенных компонентов, не доводя систему до поломки, а также более эффективно принимать решения связанные с количеством нагрузки, в зависимости от уровня изношенности компонента.

1.2 Классификация подходов к прогнозированию

Подходы к оценке остаточного времени работы механизма можно классифицировать на физические, основанные на данных и гибридные.

Первый класс подходов к прогнозированию использует явные математические представления (модель белого ящика) для формализации физического понимания изнашивающейся системы. Прогнозирование состояния с использованием таких подходов достигается при помощи накопления знаний о процессах, затрагивающих нормальное функционирование машин и вызывающих поломки. Физические подходы основываются на знании о том, что любая поломка является результатом какого-либо фундаментального процесса: электрического, химического, температурного. Основные приемы физического подхода используют моделирование на уровне материалов, к примеру, модели роста трещин и сколов или модели траектории газовых потоков в газотурбинных двигателях. Физический подход специфичен в зависимости от области приложения и предполагает, что поведение системы может быть описано аналитически и точно. Таким образом физический подход к прогнозированию поломок приемлем в случаях, когда точность прогноза перевешивает остальные факторы, например, в такой области как авиастроение. Однако, для большинства промышленных приложений, физические подходы могут быть не самым лучшим выбором, так как типы поломок варьируются и порой являются сложными для идентификации. Также изменения в нагрузке оборудования влияют на распространение неисправности. Поэтому в динамической среде, физическая модель может быть неточной из-за сделанных допущений.

Подходы, основанные на данных, могут рассматриваться как модели черного ящика, которые изучают поведение исследуемой системы напрямую из данных, собранных во время мониторинга (вибрационный акустический сигнал, давление, температура, напряжение и т.д.). Эти подходы основываются на допущении, что статистические характеристики данных о системе относительно неизменны до тех пор, пока не произойдет поломка. Такие методы преобразуют чистые данные мониторинга в поведенческие модели (в том числе модель деградации) изучаемой системы. Таким образом, системы прогнозирования, основанные на данных, являются менее дорогими и имеющими больший потенциал

к применению в промышленности, так как они требуют только данных вместо априорных знаний или сотрудников-экспертов. Однако подходы, основанные на данных требуют предварительного «обучения» прогнозирующей системы, для этого процесса необходимо большое количество «тренировочных» данных.

Гибридные подходы представляют собой объединения физических и основанных на данных подходов с целью использования сильных сторон обеих категорий.

1.3 Подходы к прогнозированию на основе данных

Мной был выбран подход к прогнозированию на основе данных, который предполагает использование информационных технологий, в частности машинного обучения, для анализа данных, собранных в процессе мониторинга состояния оборудования. По сравнению с физическим и гибридным данный подход является самым быстроразвивающимся и простым в реализации. Данный подход является единственным не требующих глубоких априорных знаний о физической природе анализируемого процесса и, как следствие, не требует для реализации работы экспертов в рассматриваемой области.

Тремя основными шагами подхода являются:

1. Подготовка данных
2. Извлечение признаков
3. Построение модели на основе которой можно произвести оценку оставшегося до поломки времени

Рассмотрим процесс прогнозирования с использованием подхода на основе данных более детально.

Данные: первой задачей прогнозирования является подготовка данных. Подготовка данных это процесс сбора и хранения полезной информации о системе, которая может управляться вычислительным устройством. Этот шаг необходим для реализации программы диагностики механизма. Собираемые данные делятся на два типа:

1. Данные о событиях. Комбинируют информацию о том, что произошло с системой (поломка, установка, ремонт) и что послужило причиной этих событий.
2. Данные о состоянии. Собираются различные динамические параметры работающей системы, с целью идентификации изменений, которые послужили причиной развития поломок. Этими параметрами могут быть вибрационный сигнал, сила, температура, напряжение, акустический сигнал, влажность и т.д.

В случае подшипника качения, например, для сбора тестовых данных используют устройства как на рис. 1.1. Несколько подшипников устанавливаются на вал, снабжаются датчиками вибрационного сигнала, акселерометрами и тер-

мопарами. Далее к ним прикладывается постоянная нагрузка и система запускается. Тест продолжается до поломки одного из подшипников. В этом случае данными о событиях будет информация о фактах поломок подшипников (время, природа поломки и т.д.). А данными о состоянии будет информация, собранная с датчиков на всем протяжении теста.




Рисунок 1.1 — Устройство для тестирования подшипника качения

Признаки: чистые данные собранные на предыдущем шаге зачастую являются избыточными и зашумленными и не могут быть использованы в прогностической модели напрямую. Другими словами, информация, относящаяся к процессу деградации скрыта в чистых данных, потому данные должны быть обработаны, чтобы выделить признаки. Под признаком понимается результат некоторого преобразования сигнала, на основе которого можно судить о тех или иных процессах, происходящих в системе. Признаки можно рассматривать как многомерные данные, изменяющиеся во времени.

Среднеквадратичное отклонение (RMS) демонстрирует энергию вибрационного сигнала. Это также является основным показателем при оценке вибрации вращающихся механизмов.

На рис. 1.2 показаны изменения среднеквадратичного отклонения и эксцесса (kurtosis) в процессе жизненного цикла подшипника. Очевидно, что среднеквадратичное отклонение со временем увеличивается, однако эксцесс имеет отличие в том, что его интенсивность снижается при непосредственном приближении поломки. Эксцесс может предоставить информацию о возникновении неисправности, однако он не может предоставить информацию о деградации подшипника. Так как у эксцесса для нормального состояния и состояния силь-




Рисунок 1.2 — Среднеквадратичное отклонение и эксцесс вибросигнала подшипника

ного износа разница в данных невелика, это может привести к некорректной оценке состояния подшипника. С другой стороны, для надежности, в модели следует рассматривать различные параметры. Хотя среднеквадратичное отклонение лучше эксцесса, оно сильно увеличивается под конец эксперимента. Что означает, что такой выбор также недостаточно надежен для построения модели. RMS здесь используется больше для проверки эффективности метода. Поэтому RMS используется для одного из характеристических параметров метода LRM.

Модель: основная задача прогнозирования - это построение эффективной модели на основании которой можно сделать прогноз остаточного ресурса механизма. Стратегии прогнозирования в рамках подходов на основе данных можно разделить на три группы:

1. Одномерное моделирование деградации: на основании собранных данных по одному признаку строится регрессионная модель. По этой модели оценивается время пересечения сигналом «границы поломки», откуда можно вычислить остаточный ресурс системы. Однако «границу поломки» тяжело определить, что ограничивает применимость данной стратегии моделирования.
2. Многомерное моделирование деградации: цель многомерного моделирования деградации в объединении модели деградации и модели классификации, чтобы точно найти «границу поломки». Таким образом остаточный ресурс может быть спрогнозирован на основании цепочки классификаций состояния системы. Основным ограничением данной схемы

является предположение о количестве промежуточных состояний деградации. Каждая машина может вести себя по-разному, даже в одних и тех же условиях, что означает возможность наличие разных промежуточных состояний деградации. Так, количество состояний не может быть одинаковым для всех машин. Поэтому «граница поломки» может варьироваться и должна назначаться динамически. Несмотря на это, многомерное моделирование считается имеющим наибольший потенциал и выглядит более реалистичным по сравнению с альтернативами.

3. Прямой прогноз остаточного ресурса изучает соотношения между трендами, наблюдаемыми в чистых данных и реальным временем поломки. Таким образом оценка остаточного ресурса выводится путем сравнения с образцом (поиска схожестей). Данная стратегия не требует определения критерия поломки, а полагается на монотонные тренды для осуществления сравнения с образцом. Однако малейшее отклонение от истории, из-за неопределенных условий или из-за шума, может привести к большим ошибкам в прогнозе. Также описанная процедура может быть затратной с точки зрения вычислительных ресурсов.

1.4 Классификация подходов к прогнозированию на основе данных

Также эффективность прогностической модели напрямую зависит от «качества» признаков. Важно выделить такие признаки которые содержат наибольшее количество информации о процессе деградации и отражают развитие неполадки. Для определения степени деградации подшипника по вибрационному сигналу, например, используются такие признаки как среднее квадратичное, эксцесс и др.

Большинство исследований сходятся на разделении подходов, основывающиеся на данных на два класса: с использованием методов машинного обучения и статистических.

Машинное обучение (Machine Learning) — обширный подраздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться. Различают два типа обучения. Обучение по прецедентам, или индуктивное обучение, основано на выявлении общих закономерностей по частным эмпирическим данным. Дедуктивное обучение предполагает формализацию знаний экспертов и их перенос в компьютер в виде базы знаний. Дедуктивное обучение принято относить к области экспертных систем, поэтому термины машинное обучение и обучение по прецедентам можно считать синонимами.

Машинное обучение находится на стыке математической статистики, методов оптимизации и классических математических дисциплин, но имеет также и собственную специфику, связанную с проблемами вычислительной эффективности и переобучения. Многие методы индуктивного обучения разрабатывались как альтернатива классическим статистическим подходам. Многие методы тесно связаны с извлечением информации и интеллектуальным анализом данных (Data Mining). Наиболее теоретические разделы машинного обучения объединены в отдельное направление, теорию вычислительного обучения (Computational Learning Theory, COLT).

Машинное обучение — не только математическая, но и практическая, инженерная дисциплина. Чистая теория, как правило, не приводит сразу к методам и алгоритмам, применимым на практике. Чтобы заставить их хорошо работать, приходится изобретать дополнительные эвристики, компенсирующие несоответствие сделанных в теории предположений условиям реальных задач.

Практически ни одно исследование в машинном обучении не обходится без эксперимента на модельных или реальных данных, подтверждающего практическую работоспособность метода. Общая постановка задачи обучения по прецедентам. Дано конечное множество прецедентов (объектов, ситуаций), по каждому из которых собраны (измерены) некоторые данные. Данные о прецеденте называют также его описанием. Совокупность всех имеющихся описаний прецедентов называется обучающей выборкой. Требуется по этим частным данным выявить общие зависимости, закономерности, взаимосвязи, присущие не только этой конкретной выборке, но вообще всем прецедентам, в том числе тем, которые ещё не наблюдались. Говорят также о восстановлении зависимостей по эмпирическим данным — этот термин был введён в работах Вапника и Червоненкиса.

Наиболее распространённым способом описания прецедентов является признаковое описание. Фиксируется совокупность n показателей, измеряемых у всех прецедентов. Если все n показателей числовые, то признаковые описания представляют собой числовые векторы размерности n . Возможны и более сложные случаи, когда прецеденты описываются временными рядами или сигналами, изображениями, видеорядами, текстами, попарными отношениями сходства или интенсивности взаимодействия, и т. д. Для решения задачи обучения по прецедентам в первую очередь фиксируется модель восстанавливаемой зависимости. Затем вводится функционал качества, значение которого показывает, насколько хорошо модель описывает наблюдаемые данные. Алгоритм обучения (learning algorithm) ищет такой набор параметров модели, при котором функционал качества на заданной обучающей выборке принимает оптимальное значение. Процесс настройки (fitting) модели по выборке данных в большинстве случаев сводится к применению численных методов оптимизации. Замечание о терминологии. В зарубежных публикациях термин algorithm употребляется только в указанном выше смысле, то есть это вычислительная процедура, которая по обучающей выборке производит настройку модели. Выходом алгоритма обучения является функция, аппроксимирующая неизвестную (восстанавливаемую) зависимость. В задачах классификации аппроксимирующую функцию принято называть классификатором (classifier), концептом (concept) или гипотезой (hypothesis); в задачах восстановления регрессии — функцией регрессии; иногда просто функцией. В русскоязычной литературе аппроксимирующую функ-

цию также называют алгоритмом, подчёркивая, что и она должна допускать эффективную компьютерную реализацию.




Рисунок 1.3 — Пример регрессионной модели аппроксимирующей реальные данные

Подходы, основанные на машинном обучении, используют интеллектуальные информационные системы, способные обучаться на примерах и отражать сложные взаимосвязи между собранными данными, которые с трудом поддаются формальному описанию. Таким образом названные методы могут использоваться в тех случаях, когда использование физических подходов является затруднительным. В зависимости от доступных данных, обучение систем прогноза, может производиться различным образом. Выделяют обучение с учителем и обучение без учителя. В первом случае используются данные для которых известен желаемый результат работы системы – размеченные данные. Во втором выходные данные не размечены. Машинное обучение – быстрорастущая область в сфере прогнозирования, множество алгоритмов в настоящее время разрабатывается исследователями.

Статистические подходы оценивают состояние системы путем подстройки вероятностных моделей к собранным данным. Статистические подходы просты в управлении. Как и подходы, использующие машинное обучение, они требуют достаточного количества данных мониторинга чтобы иметь возможность обучить систему прогнозирования. Стоит заметить, что статистический подход может давать большие ошибки на неполных данных, и природа данных важна в данной категории. Из известных подходов можно отметить: регрессионные методы, стохастическую фильтрацию, скрытые Марковские модели.

Обобщая, можно заключить, что сильной стороной подходов к прогнозированию, основанных на данных, является возможность преобразовывать многомерные зашумленные данные в данные более низкой размерности для произведения прогноза. Основная критика данных подходов состоит в том, что им необходимо больше данных по сравнению с физическими подходами. Достаточное количество образцов данных, охватывающих работу системы вплоть до поломки, включающих все интересующие типы поломок, необходимо системам, основанным на данных, чтобы отразить сложные взаимосвязи. Однако, некоторые промышленные системы не могут быть протестированы до поломки в связи с соответствующими последствиями. Кроме того, качество данных также имеет значение. Реальные механизмы работают в нелинейной среде и собранные данные могут быть изменчивы, зашумлены, что напрямую влияет на эффективность подходов данного класса. Поэтому важно правильно обработать данные, чтобы получить хорошие признаки, уменьшить сложность моделирования и увеличить точность оценки остаточного ресурса наблюдаемой системы.

Стоит отметить также существование гибридных подходов, которые пытаются объединить физические и основанные на данных методы прогнозирования. Идея гибридных подходов в получении преимуществ от двух методик, чтобы добиться более тонко устроенных моделей, которые будут иметь большие возможности справляться с неопределенностью, что должно вылиться в более точное предсказание остаточного ресурса.

1.5 Оценка эффективности подходов к прогнозированию

С развитием множества различных подходов к прогнозированию, возникла необходимость в методах оценки эффективности этих подходов, с целью выявления наиболее эффективных. Современные метрики эффективности прогнозирования классифицируют на категории:

1. Эффективности алгоритмов: метрики этой категории оценивают эффективность прогностических моделей по ошибкам полученных из реального и спрогнозированного времени до поломки.
2. Вычислительной эффективности: метрики этой категории фокусируются на важности вычислительной производительности прогностических моделей, в особенности это касается критически важных систем, которые требуют принятия решений в короткие сроки. Так, для любого подхода эффективность в данной категории может быть измерена временем, затраченным процессором на исполнение алгоритма.
3. Эффективности с точки зрения затрат и выгод: метрики этой категории связаны с экономическими затратами и выгодами, на которые влияет внедрение системы прогнозирования основанной на каком-либо подходе. Если прогнозы системы точны, затраты будут сокращаться. Этого можно ожидать в связи с тем, что детали придется заменять реже (так как имеется точный прогноз по времени следующей поломки), а также исключаются затраты, связанные с самим фактом наличия поломок. В качестве примера метрики можно предложить среднее время между заменами детали.

Основными требованиями к системам прогнозирования являются:

1. Гибкость. Реальные промышленные системы не являются идеальными и полезность собранных данных зависит от изменчивости наблюдаемого феномена, состояния датчиков и т.д. Создание модели прогнозирования устойчивой к неопределенности является сложной задачей. Отсюда требование гибкости, определяемое как «способность подхода к прогнозированию быть нечувствительным к неотъемлемым изменениям входных данных». Это означает, что модель должна иметь стабильный результат, даже когда используются различные тренировочные наборы,

взятые из одного контекста (рабочие условия детали, материал, геометрия).

2. Надежность. Даже если подход является гибким, он также должен быть достаточно надежным чтобы быть использованным в контексте отличном от использованного в фазе моделирования (обучения). Другими словами, надежность - это «способность подхода к прогнозированию быть последовательным в ситуациях, когда системе представлены новые или неизвестные данные».
3. Применимость. Помимо первых двух требований, модель прогнозирования должны быть выбрана в соответствии с требованиями, накладываемыми реализацией в конкретных условиях. Таким образом применимость может быть определена как «способность модели прогнозирования быть практически примененной в промышленных рамках».

1.6 Метод на основе пакетного вейвлет-разложения и скрытых Марковских моделей

Данный метод использует пакетное вейвлет-разложение (ПВР) сигнала в качестве признакового описания и скрытые Марковские модели, как средство моделирования процесса износа подшипника [9].

Краткий обзор ПВР

ПВР – признак принадлежащий частотно-временной области. Для этого сигнал фильтруется фильтрами низких и высоких частот. В качестве частоты среза фильтров берется одна четвертая частоты дискретизации сигнала. Сигнал отфильтрованный фильтром высоких частот называется Detail (D), а фильтром низких частот - Approximation (A). Каждая из получившихся частей имеют длину равную половине длины изначального сигнала. и представляют собой высоко- и низкочастотные составляющие сигнала. Если подобную процедуру разложения применить еще раз к получившимся половинам сигнала, получится WPD-разложение 2-го уровня, а получившиеся слои разложения размером с четверть изначального будут называться AA (approximation of the approximation), DA (detail of the approximation), AD (approximation of the detail) and DD (detail of the detail). Совокупность энергий сигнала в каждом из слоев разложения используется как признаковое описание.

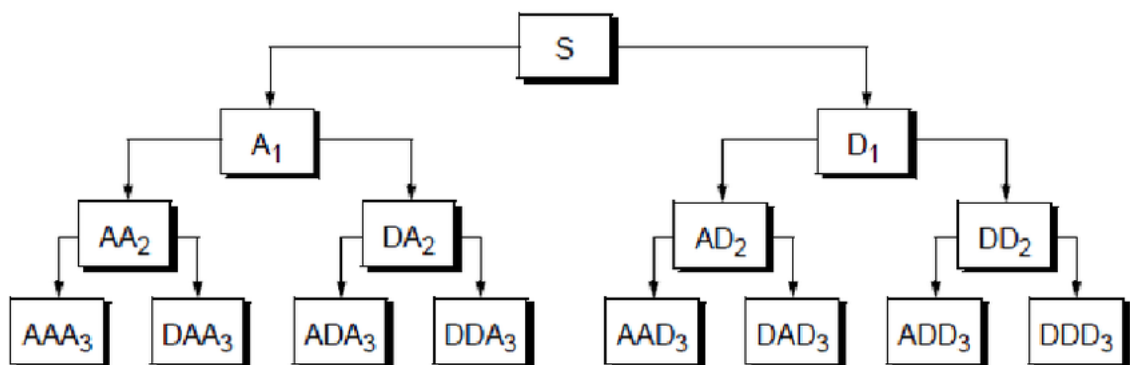


Рисунок 1.4 — Разложение сигнала третьего уровня про помощи ПВР

Скрытые Марковские модели (СММ)

Данный метод использует СММ для оценки остаточного ресурса подшипника качения. СММ характеризуется:




Рисунок 1.5 — Пример ПВР извлеченного из вибрационного сигнала подшипника

1. Некоторым числом состояний N . Состояние в момент времени t определяется как s_t
2. Количеством наблюдений для каждого из состояний M . Наблюдения обозначаются как $V = v_1, v_2, v_3, \dots, v_M$.
3. Распределением вероятностей перехода между состояниями, a_{ij} , где

$$a_{ij} = P[s_{t+1} = j | s_t = i], 1 \leq i, j \leq N.$$

4. Распределением вероятности наблюдений для каждого из состояний, $b_i(k)$, где

$$b_i(k) = P[v_k | s_t = i], 1 \leq k \leq M.$$

5. Распределением изначальных состояний, $\pi = \{\pi_i\}$


$$\pi_i = P[s_t = i], 1 \leq i \leq N.$$

Для обозначения СММ модели используется компактная нотация $H = (A, B, \pi)$

На практике СММ используются для решения нескольких задач:

1. Задачи оценки. Для данной последовательности наблюдений и СММ модели H , оценить $P(V|H)$

2. Задачи декодирования. Для последовательности наблюдений и СММ модели H , выбрать оптимальную последовательность состояний. Данная задача решается с помощью алгоритма Витерби.
3. Задачи обучения. Найти такие параметры СММ H , которые максимизируют $P(V|H)$. Эта задача решается при помощи алгоритма Баума-Велша.



	STATE		
	1	2	3
P(H)	P_1	P_2	P_3
P(T)	$1-P_1$	$1-P_2$	$1-P_3$

$$A = \{a_{ij}\} = \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix}.$$

б) Матрица вероятностей переходов

а) Состояния

Рисунок 1.6 — Скрытые Марковские модели характеризуются состояниями и вероятностями перехода между ними.

Данный метод выполняет классификацию состояния подшипников, руководствуясь моделью из трех состояний: нормального, изношенного и критического.




Рисунок 1.7 — Модель из трех состояний подшипника

1.7 Метод на основе быстрого преобразования Фурье и одноклассового метода опорных векторов

Данный метод использует быстрое преобразование Фурье (БПФ) для анализа поддиапазонов спектра сигнала и диагностики возможного наличия неисправностей. Применение БПФ к первичному вибросигналу позволяет детально определить колебательное поведение системы. При возникновении неисправности, в зависимости от исследуемого компонента, форма БПФ меняется, по сравнению с нормальным состоянием. Рассчитывается среднеквадратичное отклонение всего сигнала, а так же поддиапазонов по 50Гц (0-20000 Гц). Исследование на различных частотах вращения механизма, помогает определить различные нормальные состояния механизма, так как при отсутствии поломок уровень вибрации изменяется в зависимости от этого параметра.

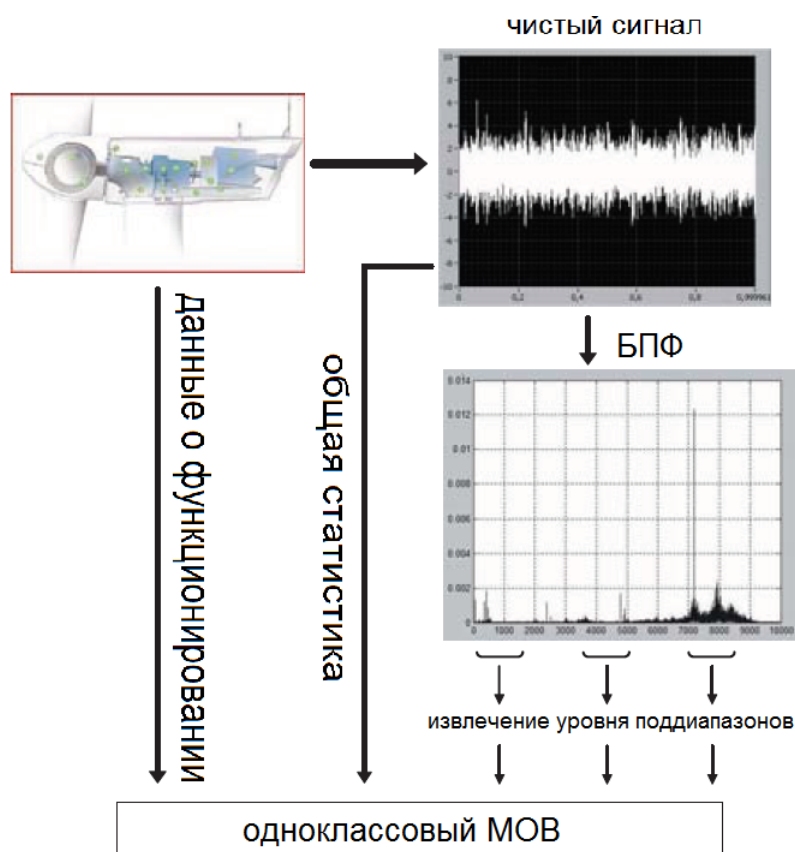


Рисунок 1.8

Для классификации используется одноклассовый метод опорных векторов (ОМОВ). Используя общий уровень вибрации механизма и интенсивность различных частот в спектре в качестве входных данных (при нормальном со-

стоянии системы), ОМОВ формирует границу отделяющую область значений признаков, соответствующих нормальному состоянию, от области аномальных значений. Таким образом обнаруживается изменение поведения при наличии неисправности с помощью ОМОВ, так как новые структуры выходят за пределы установленной области. Когда собраны данные о нормальной работе, они используются для обучения одноклассового метода опорных векторов, и полученная модель используется в дальнейшем для определения на какое состояние указывает новая информация о машине (нормальная работа, либо поломка)

Глава 2. Информационная модель качественной и количественной оценки состояния подшипника

2.1 Теория активного восприятия

ТАВ предложена профессором В. А. Утробиним. Первоначально ТАВ использовалась для анализа изображений, но была адаптирована для применения к вибросигналу. Базовым преобразованием в теории активного восприятия является U-преобразование, которое заключается в последовательных операциях интегрирования и дифференцирования, применяемых к анализируемому сигналу. Также ТАВ включает раздел «Алгебра групп», которые посвящен анализу зависимостей между спектральными коэффициентами разложения. Обнаруженные зависимости допускают свое использование при формировании системы признаков анализируемого сигнала.

2.2 U-преобразование

Пусть $f(t)$ – анализируемый вибросигнал, наблюдаемый на конечном участке времени. Результатом применения U-преобразования к сигналу $f(t)$ будет многоуровневое груботочное спектральное представление:

$$D = \{d_{ij}\}, i = \overline{1, K}, j \in \overline{1, M_i},$$

где K – число уровней разложения, M_i – количество сегментов сигнала на i -ом уровне разложения, d_{ij} – спектр, включающий L спектральных коэффициентов (число используемых фильтров), $d_{ij}\{k\}$ – k -ый спектральный коэффициент ($k = \overline{1, L}$), f_{ij} – сегмент сигнала f , по которому вычислен спектр d_{ij} .

Пример вычисления двухуровневого U-представления сигнала из 16 отсчетов:

Уровень 1. Интегрирование. Сигнал разбивается на 4 части, амплитуды отсчетов, отнесенные к каждой части складываются (см. рис. 2.1, 4 части отделены пунктиром), в результате чего получается массив сумм $S = \{12, 13, 8, 10\}$.




Рисунок 2.1 — Интегрирование сигнала (уровень 1)

Уровень 1. Дифференцирование. Применяя фильтры (показанные на рис. 2.2) к массиву сумм S , вычисляются значения спектральных коэффициентов. Для этого каждый фильтр поэлементно умножается на массив сумм S . Например, умножив массив S на фильтр №2, в результате получится массив $S_2 = -12, -13, 8, 10$, сумма элементов которого представляет собой спектральный коэффициент $(-12) + (-13) + 8 + 10 = -7$. Результаты применения всех фильтров указаны в таблице 1.

Таблица 1 — Вычисление спектральных коэффициентов уровня 1

Результат умножения				Фильтр	Спектральные коэффициенты
12	13	8	10	№1	43
-12	-13	8	10	№2	-7
-12	13	8	-10	№3	-1
12	-13	8	-10	№4	-3

Уровень 2. Интегрирование. Сигнал разбивается на 4 сегмента, каждый сегмент разбивается на 4 части, вычисляется сумма отсчетов, относящихся к каждой части (см. рис. 2.3).

Уровень 2. Дифференцирование S помощью фильтров изображенных на рисунке 2.2 и результатов интегрирования, вычисляются значения спектральных коэффициентов (см. таблицу 2).




Рисунок 2.2 — Базисные функции




Рисунок 2.3 — Интегрирование сигнала (уровень 2)

В приведенном примере для вычисления спектрального представления сигнала используются 4 фильтра изображенных на рис. 2.2, однако для решения задачи вибродиагностирования подшипника качения используются 16 фильтров для более точного анализа сигнала. Используемые фильтры изображены на рис. 2.4.

Таблица 2 — Вычисление спектральных коэффициентов уровня 2

Результат умножения								Фильтр	Спектральные коэффициенты	
сегмент 1				сегмент 2					сегмент 1	сегмент 2
3	2	4	3	4	3	2	4	№1	12	13
-3	-2	4	3	-4	-3	2	4	№2	2	1
-3	2	4	-3	-4	3	2	-4	№3	0	-3
3	-2	4	-3	4	-3	2	-4	№4	2	-1
сегмент 3				сегмент 4					сегмент 3	сегмент 4
2	2	3	1	2	2	2	4	№1	8	10
-2	-2	3	1	-2	-2	2	4	№2	0	2
-2	2	3	-1	-2	2	2	-4	№3	2	-2
2	-2	3	-1	2	-2	2	-4	№4	2	-2

2.3 Реализация системы вибродиагностики с использованием теории активного восприятия

Предварительная обработка

На этапе предварительной обработки амплитуды $\{s_i\}$ отсчетов сигнала S приводится к интервалу $[0;1]$ с помощью линейного преобразования. Это необходимо для того чтобы на этапе интегрирования положительные и отрицательные значения амплитуд не получались нулевые значения спектральных коэффициентов.

$$S_{norm} = \{s_{i_{norm}}\} = (\{s_i\} - \min(\{s_i\}))/\max(\{s_i\})$$

Далее сигнал разделяется на несколько равных частей.

$$S_{norm} = \{s_i\}, i \in \overline{1, m}, m = N/n,$$

N – количество отсчетов в сигнале, n – количество отсчетов в сегменте сигнала.

В процессе деградации подшипника качения в вибрационном сигнале неизбежно будут появляться аномалии, являющиеся следствием появления и прогрессирования микроскопических дефектов в структуре материала, из которого изготовлен подшипник. Для того чтобы иметь возможность оценить насколько далеко зашел процесс разрушения материала подшипника и, соответственно, оценить остаточный ресурс работы, необходимо иметь возможность выделять в вибрационном сигнале признаки отражающие этот процесс. На рис. 2.5 изобра-

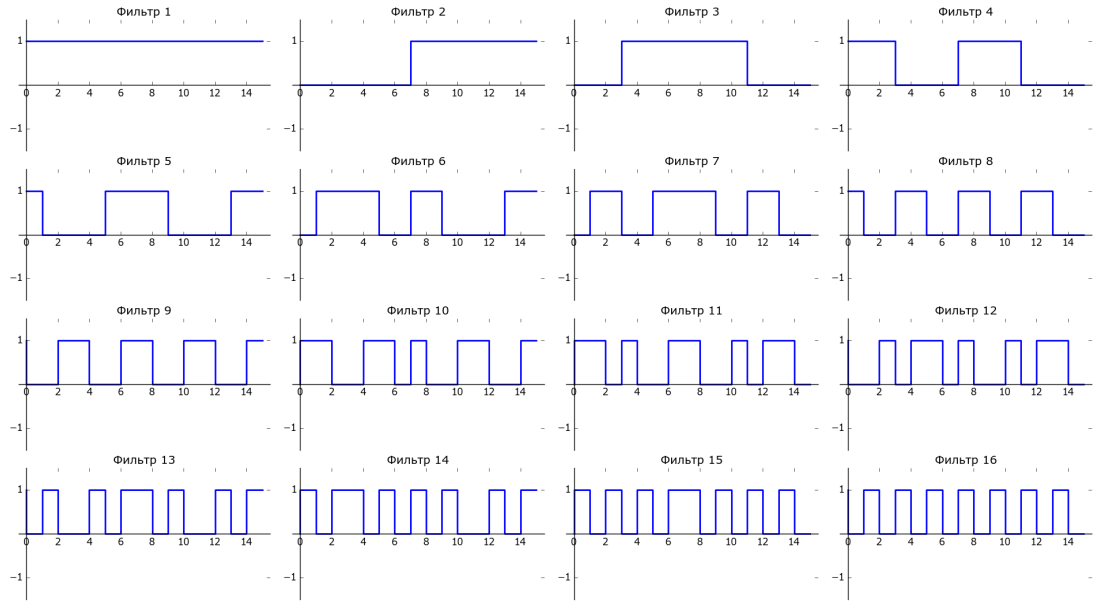


Рисунок 2.4 — Фильтры из 16 отсчетов

жен пример дискретного вибрационного сигнала собранного в результате тестирования подшипника качения до поломки. На изображении можно отчетливо видеть резкое увеличение разброса амплитуд сигнала в конце интервала, прямо перед поломкой подшипника. Также можно обратить внимание на увеличение количества выбросов в сигнале по мере процесса «старения» подшипника.

Среднеквадратичное отклонение

Используем в качестве базиса для признакового описания среднеквадратичное отклонение. Это часто используемый признак принадлежащий временной области.

$$SKO = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Пример изображен на рис. 2.6. Цветом выделены значения извлеченные из разных подшипников, которые тестировались одновременно на одном тестовом стенде до первой поломки одного из них. Отметим, что сломался подшипник, график СКО которого изображен синим цветом. На рисунке видны две аномальные области, по которым можно судить о процессе разрушения подшипника до факта поломки.




Рисунок 2.5 — Пример вибрационного сигнала

Однако использование среднеквадратичного в чистом виде нежелательно. Необходимо получение монотонного, незашумленного признака, чтобы обеспечить наилучшую предсказуемость.

Определим для этого показатель кумулятивного среднего квадратичного $\lambda(T, x_i)$, где T - время для которого рассчитывается данный показатель. Если $\{a_t\}$ это массив данных проиндексированных по времени, тогда

$$\lambda(T) = \sum_{t=0}^{t < T} \sqrt{\frac{1}{n} \sum_{t=0}^T (x_t - \bar{x})^2}$$

Рассмотрев рис. 2.7 можно убедиться в том, что во время штатной работы подшипника, в процессе износа, λ возрастает линейно, а перед самой поломкой начинается экспоненциальный рост.

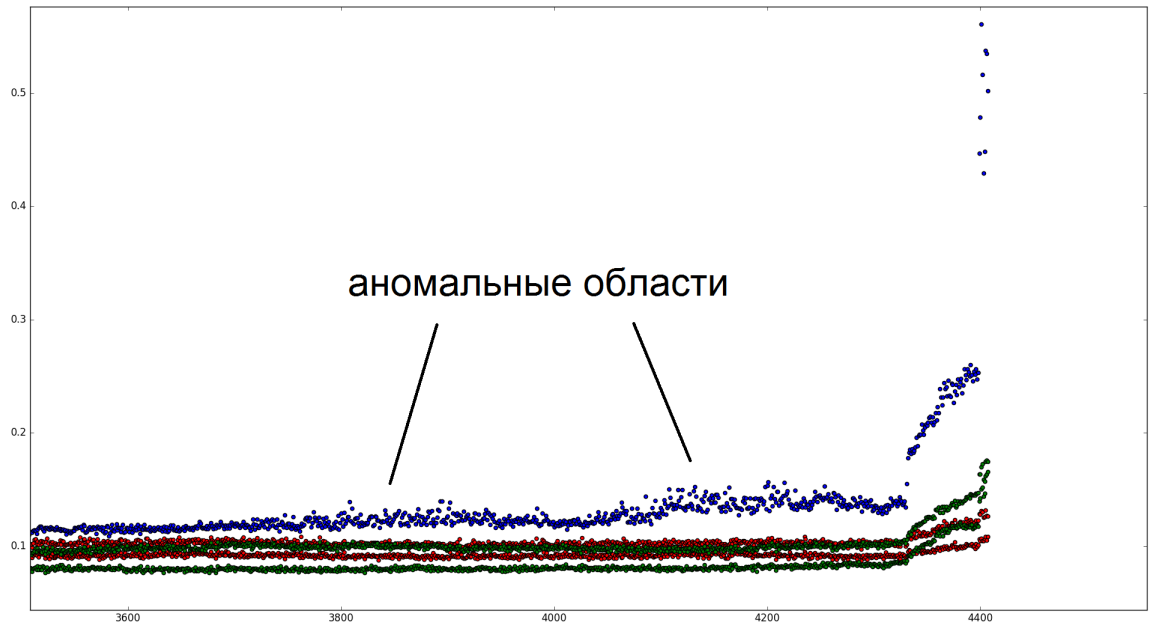


Рисунок 2.6 — Пример извлечения среднеквадратичного из сигналов нескольких подшипников. Среднеквадратичное неисправного подшипника возрастает быстрее.

2.4 Классификация

Метод опорных векторов

Метод опорных векторов (МОВ) показывает наилучшие результаты в решении задачи классификации по сравнению с другими методами. Основная идея метода — перевод исходных n векторов признаков $\{(x_i, c_i)\}$ в пространство более высокой размерности, по отношению к пространству признаков F , и поиск разделяющей гиперплоскости

$$\omega^t x + b = 0, \omega \in F, b \in R,$$

с максимальным зазором в этом пространстве. Две параллельных гиперплоскости, проходящие через некоторые из векторов признаков (опорных) векторов, строятся по обеим сторонам гиперплоскости, разделяющей классы. Разделяющей гиперплоскостью будет гиперплоскость, максимизирующая расстояние до двух параллельных гиперплоскостей, построенных на опорных векто-




Рисунок 2.7 — Кумулятивное среднеквадратическое вибрационного сигнала подшипника

рах. Алгоритм работает в предположении, что чем больше разница или расстояние между этими параллельными гиперплоскостями, тем меньше будет средняя ошибка классификатора. Поиск гиперплоскости сводится к следующей задаче оптимизации:

$$\begin{cases} \min_{\omega} \frac{1}{2}(\omega^T \omega) \\ d^i((\omega^T x^j + b) \geq 1), \end{cases}$$

где $d^i \in -1, 1$ — i -й желаемый результат, $x^i \in R^P$ — i -й входной сигнал из обучающего набора данных $\{x^i, d^i\}_{i=1}^N$.

То есть ближайшая к гиперплоскости точка находится на расстоянии $\frac{1}{\|\omega\|}$. Увеличение расстояния соответствует уменьшению евклидовой нормы опорного вектора.

После введения множителя Лагранжа и использования теоремы Куна-Таккера [5] функция принятия решения для вектора x принимает следующий вид:




Рисунок 2.8 — Оптимальная разделяющая гиперплоскость для метода опорных векторов, построенная на точках из двух классов. Ближайшие к параллельным гиперплоскостям точки называются опорными векторами

$$f(x) = \text{sign}\left(\sum_{i=1}^N d^i \alpha_i \langle x, x^i \rangle + b\right)$$

Существуют случаи когда невозможно построить разделяющую гиперплоскость, так как образцы линейно не разделимы в пространстве признаков. Для того чтобы решить данную проблему скалярное произведение $\langle x, x^i \rangle = (x^T)(x^i)$ заменяется нелинейной функцией ядра, таким образом вектора отображаются в пространство с более высокой размерностью, где образцы классов становятся линейно разделимыми.

Наиболее распространённые функции ядра:

1. Полиномиальное (однородное): $k(x, x') = (x \times x')^d$
2. Полиномиальное (неоднородное): $k(x, x') = (x \times x' + 1)^d$
3. Радиальная базисная функция: $k(x, x') = \exp(-\gamma \|x - x'\|^2)$
4. Радиальная базисная функция Гаусса: $k(x, x') = \exp(-(\frac{\|x - x'\|^2}{2\sigma^2}))$
5. СигмOID: $k(x, x') = \tanh(\kappa x \times x' + c)$

Одноклассовый метод опорных векторов


Для выделения в данных аномалий существует модификация алгоритма называемая одноклассовый метод опорных векторов (ОМОВ). В данном случае на основе тренировочных данных строится гиперплоскость, определяющая границу, отделяющую регулярные данные от аномальных (рис. 2.9). Данная модификация алгоритма отличается от других методов распознавания тем, что используется всего один класс - нормальные данные.

Задача квадратичного для ОМОВ слегка отличается от используемой в МОВ:

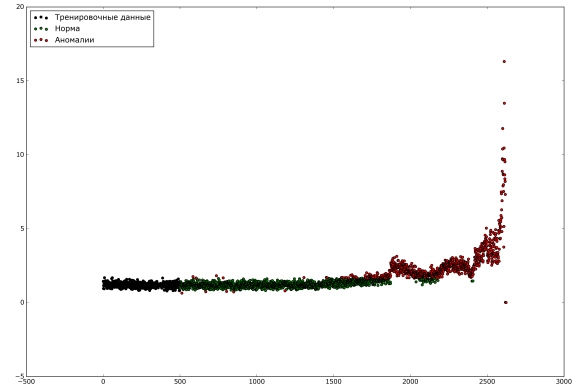
$$\begin{cases} \min_{\omega, \xi, \rho} \frac{1}{2} \|\omega\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i - \rho \\ (\omega * \phi(x_i)) \geq \rho - \xi_i, i \in \overline{1, n} \\ \xi_i \geq 0, i \in \overline{1, n} \end{cases}$$

Функция принятия решения будет выглядеть в этом случае так:

$$f(x) = \text{sign}((\omega \cdot \phi(x)) - \rho) = \text{sign}\left(\sum_{i=1}^n \alpha_i k(x, x^i) - \rho\right)$$



а) Поломка 1



б) Поломка 2

Рисунок 2.9 — Обнаружение отклонений от тренировочных данных в признаке при помощи ОМОВ

Обычным классификаторам требуются данные из всех классов определенных в задаче. Таким образом использование лишь нормальные данные для обучения ОМОВ избавляет от необходимости производить сложную и продолжительную процедуру сбора данных о поломках, во время которой состояние подшипника должно непрерывно отслеживаться.

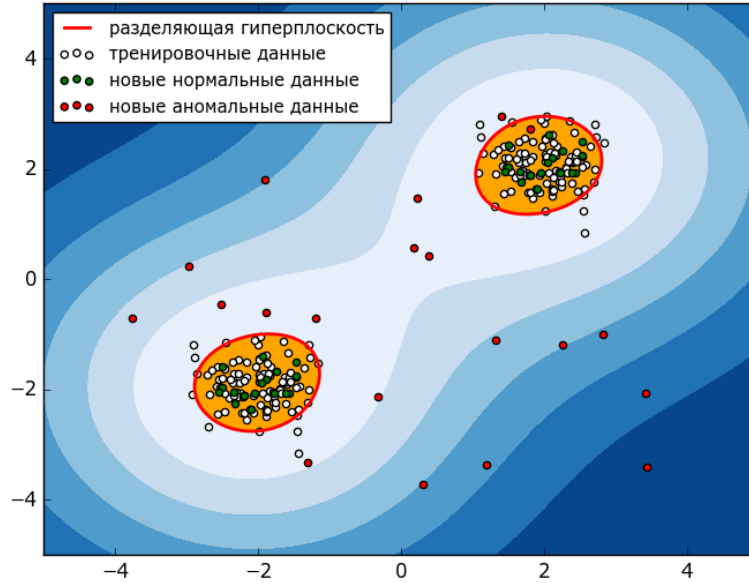


Рисунок 2.10 — Поиск аномалий в данных при помощи ОМОВ. В качестве ядра выбрана радиальная базисная функция





Как и для обычного МОВ, в случае с ОМОВ не существует автоматической системы для определения оптимальных параметров модели. Однако если руководствоваться интерпретацией параметров, задача несколько облегчается. Будем использовать ОМОВ с радиальной базисной функцией в качестве ядра.

Таким образом, с точки зрения задачи минимизации управляющих параметров системы, рассматриваемых метод использует следующие параметры:

1. Параметр радиальной базисной функции ядра γ . Этот параметр контролирует влияние индивидуальных тренировочных образцов на результирующую гиперплоскость. То есть данным параметром определяется «сглаженность» получившейся модели. Низкое значение улучшает «сглаженность» и «обобщенность» модели, а высокое делает модель лучше подогнанной к тренировочным данным.
2. Регулировочный параметр ν , который интерпретируется как максимальная доля выбросов в тренировочных данных.

Экспериментально было подобраны значения параметров $\gamma = 0.1, \nu = 0.01$ (см. рис. 2.11, 2.12).

В качестве тренировочных данных для одноклассового метода опорных векторов будем использовать сегменты вибрационного сигнала, собранные с подшипников, находящихся априори в хорошем состоянии.

а) γ слишком великб) γ отвечает требованиямРисунок 2.11 — Подбор оптимального значения параметра модели γ а) $\nu = 10\%$. Значение слишком велико.б) $\nu = 1\%$ Значение отвечает требованиям.Рисунок 2.12 — Подбор оптимального значения параметра модели ν

2.5 Описание алгоритма.

1. Амплитуды отсчетов сигнала приводятся к интервалу $[0, 1]$.
2. Сигнал разделяется на равные сегменты $\{s_{ij}\}$, длиной в n отсчетов. Выбор параметра n регулирует детализацию анализа.
3. Для каждого из сегментов разбиения сигнала при помощи U-преобразования рассчитывается массив спектральных коэффициентов $\{u_{ij}\}, i \in \overline{1, N}, j \in \overline{1, 16}, N$ – количество сегментов сигнала, полученных при разбиении.
4. Для каждого из спектральных коэффициентов u_{ij} рассчитывается среднеквадратичное отклонение. Результатом шага является массив $\{sk_{ij}\}, i \in \overline{1, N}, j \in \overline{1, 16}, N$ – количество сегментов сигнала, полученных при разбиении.




Рисунок 2.13 — Среднеквадратичное одно из спектральных коэффициентов сигнала

5. Выполняется поиск аномалий при помощи одноклассового метода опорных векторов. Это позволяет сократить количество данных на этапе моделирования. Результатом данного шага является массив $\{an_{ij}\}, i \in \overline{1, M}, j \in \overline{1, 16}$, M – количество найденных аномалий.
6. По полученному массиву аномалий an_{ij} рассчитывается кумулятивное среднеквадратическое отклонение λ .
7. Массив λ разбивается на m сегментов. Для каждого из сегментов с помощью метода опорных векторов вычисляется линейная аппроксимирующая функция φ с коэффициентом наклона k .
8. Выполняется классификация по массиву коэффициентов $\{k_{ij}\}, i \in \overline{1, M}, j \in \overline{1, 16}$. Определяется принадлежность одному из трех классов (нормальное состояние, изношенное состояние, предполомочное состояние)

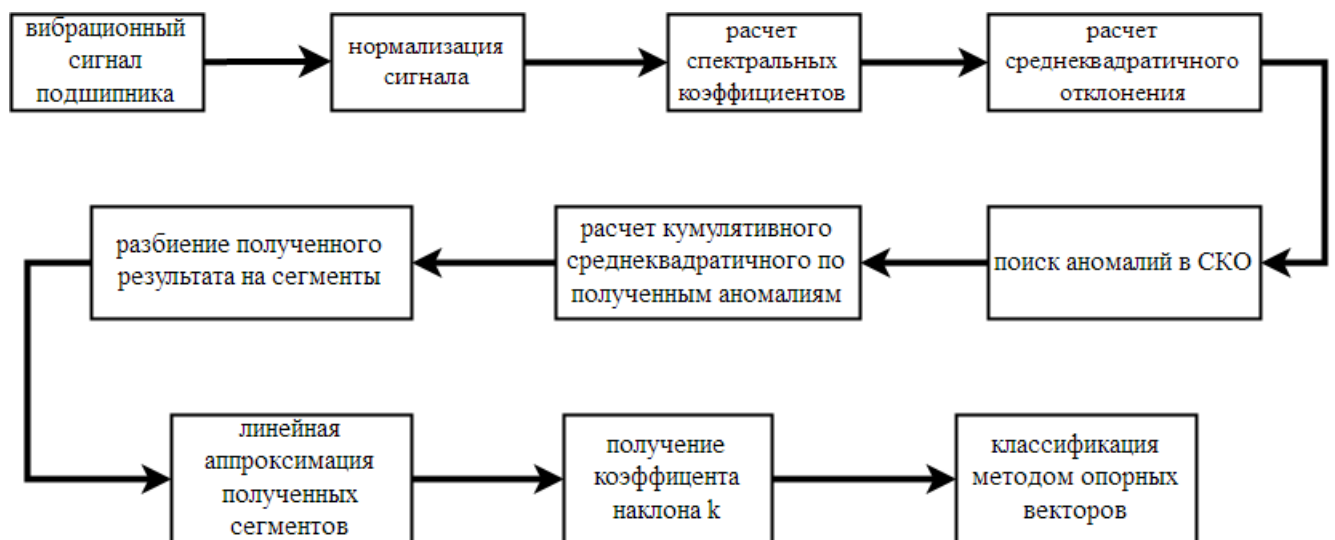


Рисунок 2.14 — Разработанная информационная модель оценки состояния подшипника

Глава 3. Вычислительный эксперимент

3.1 Эксперимент

Для проведения вычислительного эксперимента использовался пакет данных представленных в [4]. Каждый набор является результатом тестирования четырех подшипников до поломки. Каждый набор состоит из файлов содержащих 1 секунду вибрационного сигнала записанных с определенными интервалами. Частота дискретизации 20 kHz. К каждому набору прилагается номер сломавшегося подшипника и природа поломки.




Рисунок 3.1 — Стенд для тестирования подшипника качения

Для проверки работоспособности предложенного метода была проведена серия экспериментов. Результаты тестирования даны для компьютера с такими характеристиками:

1. процессор: Intel Core i7 3.2 ГГц;
2. оперативная память 16 Гб.

Предложенный метод оценки состояния релизован по большей части на языке программирования Python, наиболее требовательные к производительности функции релизованы в среде Java.

Реализованная программа работает в два шага:

На первом шаге системе предоставляются данные для обучения. Данные представляют собой сигнал, размеченный по трем состояниям:

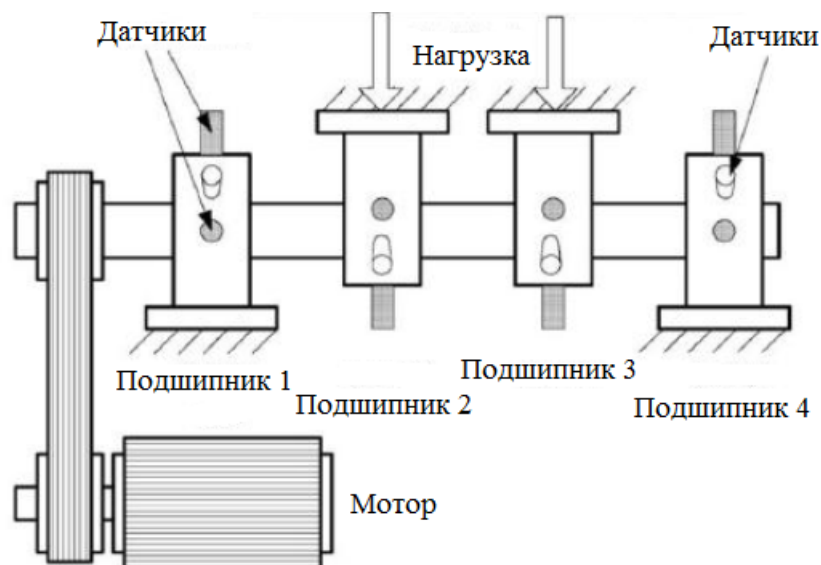


Рисунок 3.2 — Схема стенда для тестирования подшипника качения

1. Состояние 1 – нормальное
2. Состояние 2 – изношенное
3. Состояние 3 – критическое

На втором шаге системе передается сигнал для классификации. Система определяет состояние в котором находится подшипник и запоминает времена переходов между состояниями. Выдается текущее состояние и время которое система находится в данном состоянии.

Было проведено сравнение работоспособности предложенного метода использующего признаковое описание на основе среднеквадратичного по спектральным коэффициентам (КСС) с аналогичными методами прогнозирования состояния подшипника, работающими по трем состояниям (см. таблицу 3) Сравнение производилось по показателю R , выраженному в процентах и отражающему точность определения временной границы состояния подшипника.

Таблица 3 — Результаты вычислительного эксперимента для незашумленного сигнала

Признаки	Метод классификации	R , в % состояние 1	R , в % состояние 2
ПВР	СММ	79,58	80,65
ПВР	МОВ	97,7	98,24
СКО	СММ	95	97,22
КСС	МОВ	95,13	98,27

Проверка предложенного метода на зашумленном сигнале

Проанализируем влияние шума в сигнале на эффективность работы алгоритма. Добавим в анализируемый сигнал гауссовский шум. Используем соотношения сигнал/шум 20дБ, 10дБ, 0.1 дБ.

$$SNR(dB) = 10\log_{10}(P_{sig}/P_{noise}) = 20\log_{10}(A_{sig}/A_{noise}),$$

где SNR – отношение сигнал/шум, P – средняя мощность, а A – средне-квадратичное значение амплитуды [15]

Результаты эксперимента представлены в таблице 4

Таблица 4 — Результаты вычислительного эксперимента для зашумленного сигнала

Уровень шума, дБ	R, в % состояние 1	R, в % состояние 2
20	94,38	97,33
10	93,21	96,02
0.1	78,88	79,58

3.2 Выводы

В данной главе было представлено описание используемых для эксперимента данных, обзор разработанной программной системы и результаты вычислительных экспериментов, которые показывают работоспособность предложенного метода прогнозирования состояния подшипника качения. Точность работы данного алгоритмы находится на одном уровне с конкурирующими алгоритмами, предлагаемыми другими исследователями. Также по результатам экспериментальных проверок можно прийти к выводу, что предлагаемый алгоритм устойчив к шумам. Данный факт делает алгоритм пригодным для работы с производственных условиях, где уровень зашумленности бывает довольно высок.

Заключение

Основные результаты работы заключаются в следующем.

1. Исследованы методы диагностики состояния подшипника качения по вибрационному сигналу
2. Разработана новая информационная модель оценки состояния подшипника
3. Реализован алгоритм на основе разработанной информационной модели.
4. Проведен вычислительный эксперимент, подтверждающий жизнеспособность разработанного алгоритма

Список сокращений и условных обозначений

ТАВ - Теория Активного Восприятия

МОВ(SVM) - Метод Опорных Векторов

ОМОВ(One-Class SVM) - Одноклассовый Метод Опорных Векторов

(РМОВ(SVR)) - Регрессионный Метод Опорных Векторов

ПВР(WPD) - Пакетное Вейвлет-Разложение

СММ(НММ) - Скрытые Марковские модели

КСС - Кумулятивное среднеквадратичное по спектральным коэффициен-

там

СКО - Среднеквадратичное отклонение

БПФ - Быстрое преобразование Фурье

Список литературы

1. Утробин, В. А. Компьютерная обработка изображений. Анализ и синтез: учеб. пособие /В.А. Утробин; НГТУ. Нижний Новгород, 2003. 228с
2. Утробин В.А. Физические интерпретации элементов алгебры изображений // Успехи физических наук, Т. 174, №10, 2004, С.1089–1104.
3. Гай, В. Е. Метод оценки частоты основного тона в условиях помех // Цифровая обработка сигналов. 2013. № 4. С. 72–76.
4. J. Lee, H. Qiu, G. Yu, J. Lin, and Rexnord Technical Services (2007). IMS, University of Cincinnati. "Bearing Data Set NASA Ames Prognostics Data Repository (<http://ti.arc.nasa.gov/project/prognostic-data-repository>), NASA Ames Research Center, Moffett Field, CA
5. Воронцов К. Лекции по методу опорных векторов // ВЦ РАН. 2007.
6. Eker, Camci, Jennions Major Challenges in Prognostics: Study on Benchmarking Prognostics Datasets // 1st European Conference of the Prognostics and Health Management (PHM) Society, 6th-8th July (2012)
7. Rabiner, L. A Tutorial on hidden Markov Models and Selected Applications in Speech Recognition
8. Smola, Alex J.; Schölkopf, Bernhard (2004). "A tutorial on support vector regression". *Statistics and Computing* 14 (3): 199–222.
9. Sloukia et al. Bearings prognostic using mixture of gaussians hidden markov model and support vector machine, 2013
10. P. O'Donnell, "Report of large motor reliability survey of industrial and commercial installations, part I, II and III," *IEEE Transactions on Industry Applications*, vol. 21, pp. 853–872, 1985.
11. Peng, Y., Dong, M., and Zuo, M. J. Current status of machine prognostics in condition-based maintenance: a review. *The International Journal of Advanced Manufacturing Technology* 50, 1-4 (2010), 297–313.
12. Zhang, H., Kang, R., and Pecht, M. A hybrid prognostics and health management approach for condition-based maintenance. In *Industrial Engineering and Engineering Management*, 2009. IEEM 2009. IEEE International Conference on (2009), IEEE, pp. 1165–1169.

13. Si, X.-S., Wang, W., Hu, C.-H., and Zhou, D.-H. Remaining useful life estimation—a review on the statistical data driven approaches. *European Journal of Operational Research* 213, 1 (2011), 1–14.
14. Dragomir, O. E., Gouriveau, R., Dragomir, F., Minca, E., Zerhouni, N., et al. Review of prognostic problem in condition-based maintenance. In *European Control Conference, ECC'09 (2009)*, pp. 1585–1592.
15. Википедия – Отношение сигнал/шум / Wikipedia. URL: https://ru.wikipedia.org/wiki/%D0%9E%D1%82%D0%BD%D0%BE%D1%88%D0%B5%D0%BD%D0%B8%D0%B5_%D1%81%D0%B8%D0%B3%D0%BD%D0%B0%D0%BB/%D1%88%D1%83%D0%BC (дата обр. 2017).

Список рисунков

1.1	Устройство для тестирования подшипника качения	11
1.2	Среднеквадратичное отклонение и эксцесс вибросигнала подшипника	12
1.3	Пример регрессионной модели аппроксимирующей реальные данные	16
1.4	Разложение сигнала третьего уровня про помощи ПВР	20
1.5	Пример ПВР извлеченного из вибрационного сигнала подшипника	21
1.6	Скрытые Марковские модели характеризуются состояниями и вероятностями перехода между ними.	22
1.7	Модель из трех состояний подшипника	22
1.8	23
2.1	Интегрирование сигнала (уровень 1)	26
2.2	Базисные функции	27
2.3	Интегрирование сигнала (уровень 2)	27
2.4	Фильтры из 16 отсчетов	29
2.5	Пример вибрационного сигнала	30
2.6	Пример извлечения среднеквадратичного из сигналов нескольких подшипников. Среднеквадратичное неисправного подшипника возрастает быстрее.	31
2.7	Кумулятивное среднеквадратическое вибрационного сигнала подшипника	32
2.8	Оптимальная разделяющая гиперплоскость для метода опорных векторов, построенная на точках из двух классов. Ближайшие к параллельным гиперплоскостям точки называются опорными векторами	33
2.9	Обнаружение отклонений от тренировочных данных в признаке при помощи ОМОВ	34
2.10	Поиск аномалий в данных при помощи ОМОВ. В качестве ядра выбрана радиальная базисная функция	35
2.11	Подбор оптимального значения параметра модели γ	36
2.12	Подбор оптимального значения параметра модели ν	36

2.13	Среднеквадратичное одного из спектральных коэффициентов сигнала	37
2.14	Разработанная информационная модель оценки состояния подшипника	38
3.1	Стенд для тестирования подшипника качения	39
3.2	Схема стенда для тестирования подшипника качения	40

Список таблиц

1	Вычисление спектральных коэффициентов уровня 1	26
2	Вычисление спектральных коэффициентов уровня 2	28
3	Результаты вычислительного эксперимента для незашумленного сигнала	40
4	Результаты вычислительного эксперимента для зашумленного сигнала	41